


CUP IT 2026

Построение единой модели высотности
зданий



Моделирование высот зданий позволяет обеспечить более стабильное качество связи и высокий уровень удовлетворенности клиентов МТС



КОНТЕКСТ

Исходные данные о зданиях разрознены.

Два источника с:

- противоречивой геометрией
- аномальными значениями
- пропусками высот
- несовпадающими адресами

Без обработки такие данные непригодны для моделирования покрытия сети.

РЕШЕНИЕ

Разработан пайплайн:

Очистка геоданных



Сопоставление источников



ML-модель для
восстановления высоты



Валидация и визуализация

РЕЗУЛЬТАТ

✓ Повышение качества связи и более точное покрытие сети

✓ Оптимизация размещения и настройки сетевой инфраструктуры


✓ Повышение точности данных о городской застройке

Ключевая задача заключается в отборе качественной информации, способной
влиять на эффективность развития сетевой инфраструктуры компании.



EDA

Методы очистки данных



Пропуски
адресов в А



Пропуски
этажности в А

4 260

Нулевая средняя
высота этажа в Б

420

Ошибка
min > max в А

17

Отрицательная
этажность в Б

2

Завышенная средняя
высота этажа в Б

66

Пропуски
высоты в Б

8/7

Невалидные отверстия
в полигонах

1 929/9

Мусорные
объекты (<15 м²)

- 1. **Исправление геометрии**
 - удалены объекты <15 м² (1 929 в А, 9 в Б)
 - исправлены невалидные полигоны
- 2. **Унификация системы координат**
 - перевод в EPSG:32635
- 3. **Заполнение пропусков**
 - avg_floor_height → медиана по типу
 - purpose → 'unknown'
 - stairs → медиана по типу
- 4. **Исправление логических ошибок**
 - min/max этажности поменяны местами (420)
- 5. **Удаление выбросов**
 - stairs ≤ 0, avg_floor_height > 10
 - пропуски height
- 6. **Пространственное сопоставление**
 - 139 649 физических зданий

Корректный выбор алгоритма сопоставления объектов из разных источников является ключевым условием для предсказания недостающих данных



1. Приведение данных к единому виду

Цель: сделать оба набора данных сопоставимыми.

2. Приведение координат к одной системе

Цель: согласовать объекты

Переводим оба набора в одну систему координат, иначе расстояния и пересечения будут считаться неправильно.

3. Подготовка геометрии для сопоставления

Цель: упростить вычисления расстояний и пересечений.



4. Поиск соседних объектов между наборами

Цель: найти кандидатов на совпадение.

5. Расчет метрик близости

Цель: понять, насколько объекты похожи.

6. Формирование связей между объектами

Цель: зафиксировать возможные соответствия.

7. Построение компонент связности

Цель: объединить связанные объекты в группы.

8. Определение типа каждой группы

Цель: понять структуру соответствия.

Разделяем группы на типы:
только из одного источника
один к одному
один ко многим
многие ко многим

9. Выбор итоговой геометрии

Цель: определить, какую форму здания считать основной.

10. Разрешение конфликтов

Цель: выбрать корректные значения при расхождениях.

Важно провести сравнительный анализ моделей и выбрать ту, которая обеспечивает наилучшее качество предсказаний



Модель	Feature set	RMSE ↓	MAE ↓	R ² ↑
CatBoost	full	0.6868	0.0687	0.9892
HistGradientBoosting	full	0.7198	0.0347	0.9895
Random Forest	full	1.6400	0.3191	0.9722
CatBoost	baseline	2.6061	0.3700	0.9351
Random Forest	baseline	2.6460	0.3836	0.9332

CatBoost выбран в качестве итоговой модели по следующим причинам:


1. Лучшее качество по ключевой метрике (RMSE).
Минимизирует крупные ошибки предсказания высоты.
2. Устойчивость к пропускам и шуму
- корректно обрабатывает отсутствующие значения
- лучше работает на реальных данных с дефектами
3. Нативная работа с категориальными признаками
- не требует OneHotEncoding
- не раздувает пространство признаков
- автоматически учитывает взаимодействия

4. Хорошая обобщающая способность
- не переобучается на локальные геометрические паттерны
- стабильно работает в spatial CV

Валидация результатов позволяет подтвердить устойчивость алгоритма слияния и обоснованность выбора модели



Заполнение высот



Предсказанные
высоты (CatBoost)

Наблюдаемые высоты (из
источников)

Физическая достоверность

Высота зданий	Минимум	Максимум
Площадь зданий	2.5 м	462.0 м
Площадь зданий	4.0 м ²	141 492 м ²
Этажность	1	38

Выбросы: 1 здание
(Лахта-центр, 462 м)

Геометрическая корректность

- 100% Успешно преобразовано геометрий
- 0 Невалидных полигонов
- 0 Пустых геометрий
- 0 Нулевая / отрицательная площадь


Вывод

- ✓ Все геометрии валидны
- ✓ Все здания имеют высоту
- ✓ Диапазоны соответствуют реальной застройке
- ✓ Пространственная логика соблюдена (95% зданий согласованы с соседями)
- ✓ ML-заполнение выполнено корректно (только там, где не было данных)

Pipeline решения

От разведки и очистки данных до сопоставления, обучения модели и картографической визуализации

Data → Matching → ML → Maps



● основные этапы пайплайна ● критические точки сопоставления и проверки ● дополнительные артефакты: визуалы, признаки, метрики

EDA • QUALITY DASHBOARD

Дэшборд первичного анализа

Краткий обзор качества данных источников перед дальнейшей очисткой и объединением данных.



Всего объектов
332 530
Общий объем двух источников

Строки с пропусками
10
Количество объектов, где есть хотя бы один пропуск

Некорректные геометрии
0
Объекты, требующие геометрической очистки

Подозрительные дубликаты
86
Кандидаты в дубликаты по геометрической сигнатуре

ОБЩАЯ КАРТИНА
332 530
На одной странице собраны только ключевые показатели, которые помогают быстро понять качество источников перед их объединением.

Источник А
171 454 объектов

Размер набора
171 454 × 8
Строки и колонки исходного источника

Строки с пропусками
5
Доля от всех объектов - 0,0%

Оценка качества
100
Низкий риск

Некорректные геометрии
0
Доля от объектов - 0,0%

Отсутствующие геометрии
0 / 0
Null - 0,0% / Empty - 0,0%

Успешный разбор геометрии
100,0%
Доля корректно прочитанных объектов в проверочной выборке

Подозрительные дубликаты
52
Кандидаты по сигнатуре - 0,0%

Ошибки контуров
8
Объекты с проблемами во внутренних границах

Числовые аномалии / площадь
420 / 171 454
Аномальные значения / объекты с заметным расхождением площади

Источник В
161 076 объектов

Размер набора
161 076 × 17
Строки и колонки исходного источника

Строки с пропусками
5
Доля от всех объектов - 0,0%

Оценка качества
100
Низкий риск

Некорректные геометрии
0
Доля от объектов - 0,0%

Отсутствующие геометрии
0 / 0
Null - 0,0% / Empty - 0,0%

Успешный разбор геометрии
100,0%
Доля корректно прочитанных объектов в проверочной выборке

Подозрительные дубликаты
34
Кандидаты по сигнатуре - 0,0%

Ошибки контуров
9
Объекты с проблемами во внутренних границах

Числовые аномалии
4 281
Аномальные значения основных числовых признаков

Сравнение
A vs B

Объем данных

A: 171 454

B: 161 076

Строки с пропусками

A: 5

B: 5

Некорректные геометрии

A: 0

B: 0

Подозрительные дубликаты


A: 52


B: 34

Главный приоритет — геометрическая корректность, потому что именно она определяет надежность пространственного сопоставления объектов.

Пропуски оценены по числу строк, затронутых неполнотой, а не по сумме всех пустых ячеек.

Подозрительные дубликаты и ошибки в контурах полезно разбирать до объединения источников, чтобы не переносить шум в итоговый датасет.





POST-ML • VALIDATION DASHBOARD

Валидация результатов

Пост-ML валидация итогового датасета: геометрическая корректность, полнота высот, согласованность источников и пространственная правдоподобность результатов.



Всего зданий

139 649

Финальный датасет после сопоставления и заполнения высот

Высота заполнена

100,0%

139 649 из 139 649 объектов

Геометрия валидна

100,0%

Пустые, нулевые и невалидные полигоны не обнаружены либо сведены к минимуму

Предсказано моделью

27,3%

38 086 зданий получили высоту через CatBoost

ОБЩАЯ КАРТИНА

139 649

Итоговый набор после сопоставления, обучения и заполнения высот. Проверяем, что данные не только полны, но и логически согласованы.

Геометрия и полнота

53 колонок • 118,20 MB

Интегральная оценка валидации

100

Данные согласованы

Геометрическая корректность

Успешно разобрано

139 649 / 139 649

Доля успешного разбора - 100,0%

Невалидные геометрии

0

Доля от набора - 0,0%

Пустые / нулевая площадь

0 / 0

Пустые полигоны и вырожденные контуры

Отрицательная площадь

0

Физически невозможные значения площади

Полнота ключевых полей

target_height_filled

0

Пропусков - 0,0%

target_height_was_predicted

0

Пропусков - 0,0%

union_area_all

0

Пропусков - 0,0%

median_stairs_b

38 086

Ожидается для A_only - 27,3%

median_avg_floor_height_b

38 086

Связано с отсутствием данных источника B - 27,3%

Диапазоны и ML-логика

Observed vs CatBoost

Физическая достоверность значений

Высота

2,5 — 462,0 м

Отрицательных значений - 0

Этажность

1,0 — 38,0

Отрицательных значений - 0

Площадь

4,0 — 141 492,3 м²

Отрицательных значений - 0

Высотные выбросы

>300 м: 1

>500 м: 0

Целостность заполнения высот

Observed

101 563

Доля от набора - 72,7%

CatBoost

38 086

Доля от набора - 27,3%

Изменено observed

0

Должно быть 0: исходные наблюдения нельзя перезаписывать

Predicted c original height

0

Должно быть 0: модель заполняет только отсутствующие значения

Observed / predicted

Краткая статистика

Observed mean / median

9,5

4,5

Predicted mean / median

3,4

3,4

Observed min / max

2,5

462,0

Predicted min / max

3,1

3,9

Predicted std

0,03

узкий разброс