CUP IT 2026

Построение единой модели высотности зданий

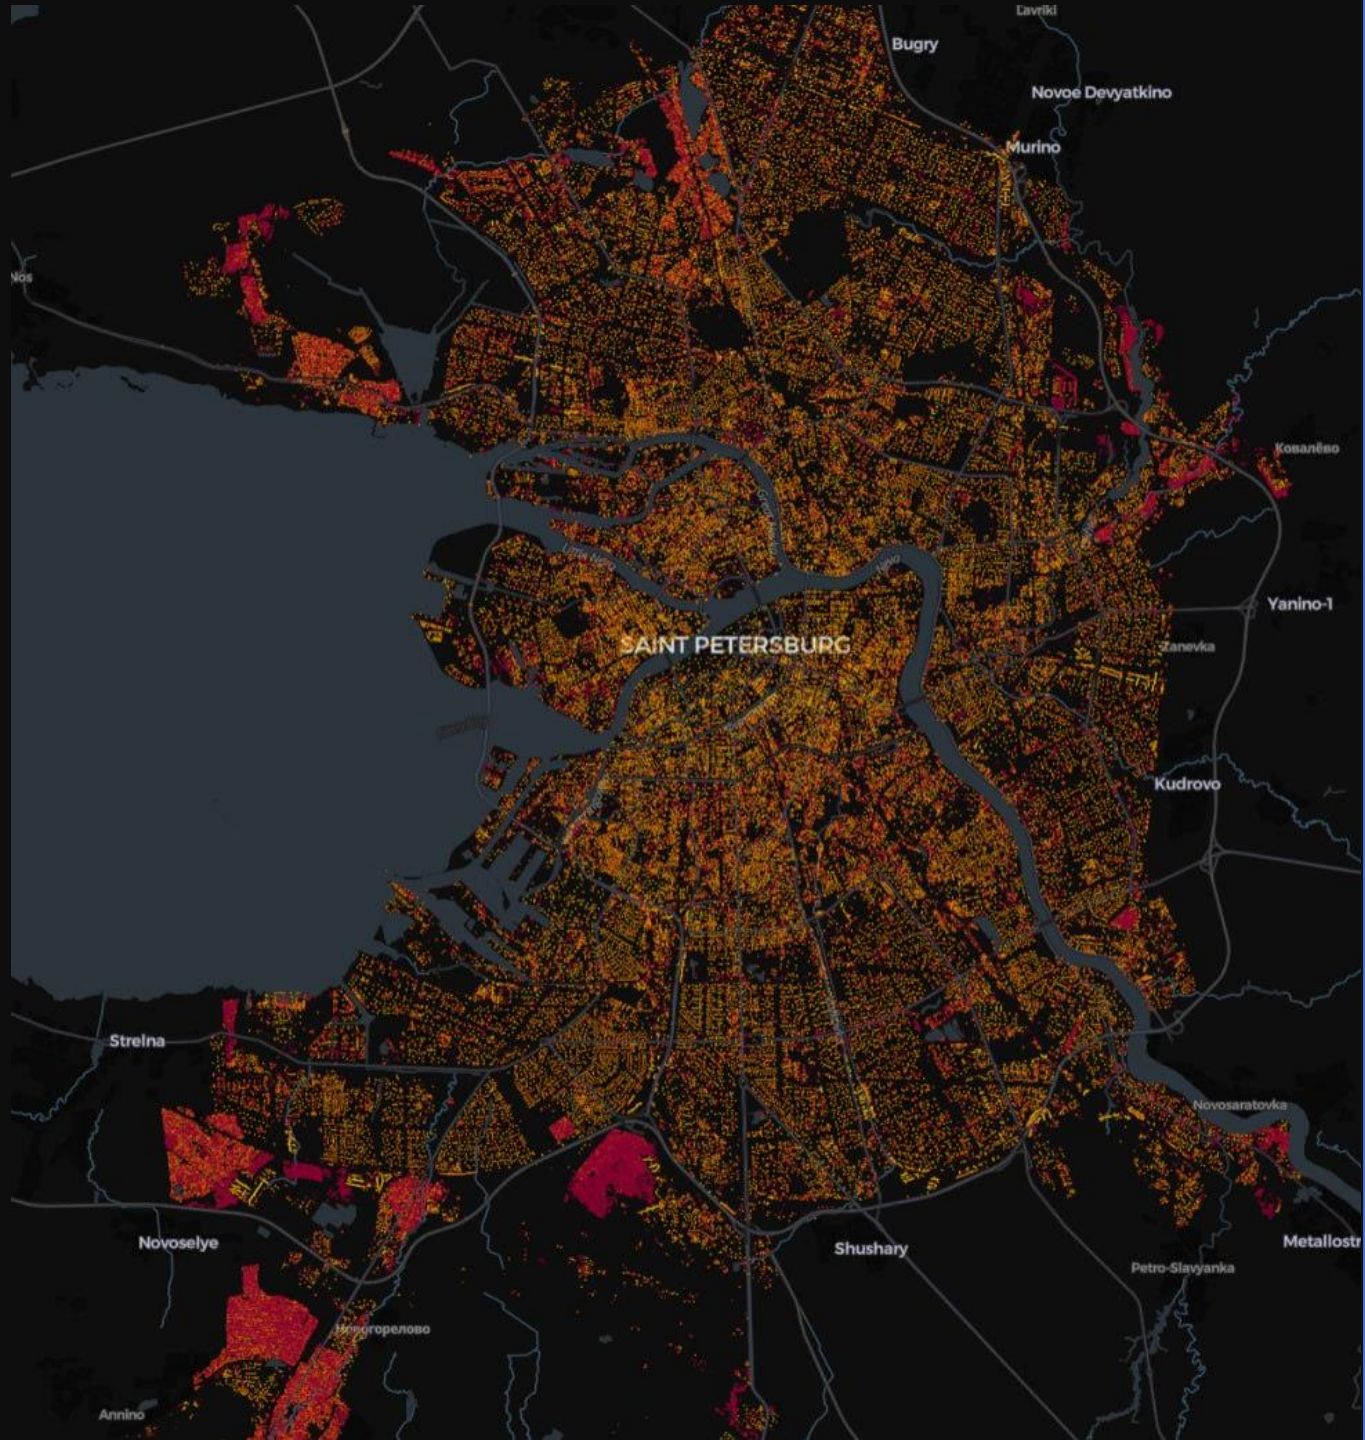

Команда: ИТМО, факультет безопасности информационных технологий

Матвеев Илья
@hep2014
409097@edu.itmo.ru
Аналитик данных

Кабанова Анастасия
@anastaness
k.anastasia39@mail.ru
Аналитик данных

Мясников Евгений
@Myzn1k
zhekmyas@mail.ru
Инженер данных

Моделирование высот зданий позволяет обеспечить более стабильное качество связи и высокий уровень удовлетворенности клиентов МТС

КОНТЕКСТ

Исходные данные о зданиях разрознены.
Два источника с:

- противоречивой геометрией
- аномальными значениями
- пропусками высот
- несовпадающими адресами

Без обработки такие данные непригодны для моделирования покрытия сети.

РЕШЕНИЕ

Разработан пайплайн:

Очистка геоданных
↓
Сопоставление источников
↓
ML-модель для восстановления высоты
↓
Валидация и визуализация

РЕЗУЛЬТАТ

✓ Повышение качества связи и более точное покрытие сети

✓ Оптимизация размещения и настройки сетевой инфраструктуры

✓ Повышение точности данных о городской застройке

Ключевая задача заключается в отборе качественной информации, способной влиять на эффективность развития сетевой инфраструктуры компании.

EDA

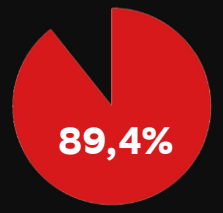

Пропуски адресов в А

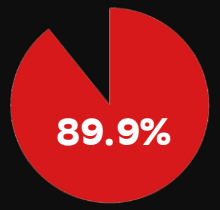

Пропуски этажности в А

4 260

Нулевая средняя высота этажа в Б

420

Ошибка min > max в А

17

Отрицательная этажность в Б

2

Завышенная средняя высота этажа в Б

66

Пропуски высоты в Б

8/7

Невалидные отверстия в полигонах

1 929/9

Мусорные объекты (<5 м²)

Методы очистки данных

1. **Исправление геометрии**
   - удалены объекты <15 м² (1 929 в А, 9 в Б)
   - исправлены невалидные полигоны
2. **Унификация системы координат**
   - перевод в EPSG:32635
3. **Заполнение пропусков**
   - avg_floor_height → медиана по типу
   - purpose → 'unknown'
   - stairs → медиана по типу
4. **Исправление логических ошибок**
   - min/max этажности поменяны местами (420)
5. **Удаление выбросов**
   - stairs ≤ 0, avg_floor_height > 10
   - пропуски height
6. **Пространственное сопоставление**
   - 139 649 физических зданий

Корректный выбор алгоритма сопоставления объектов из разных источников является ключевым условием для предсказания недостающих данных

1. Приведение данных к единому виду
Цель: сделать оба набора данных сопоставимыми.

2. Приведение координат к одной системе
Цель: согласовать объекты
Переводим оба набора в одну систему координат, иначе расстояния и пересечения будут считаться неправильно.

3. Подготовка геометрии для сопоставления
Цель: упростить вычисления расстояний и пересечений.

4. Поиск соседних объектов между наборами
Цель: найти кандидатов на совпадение.

5. Расчет метрик близости
Цель: понять, насколько объекты похожи.

6. Формирование связей между объектами
Смысл: зафиксировать возможные соответствия.

7. Построение компонент связности
Смысл: объединить связанные объекты в группы.

8. Определение типа каждой группы
Смысл: понять структуру соответствия.
Разделяем группы на типы:
только из одного источника
один к одному
один ко многим
многие ко многим

9. Выбор итоговой геометрии
Смысл: определить, какую форму здания считать основной.

10. Разрешение конфликтов
Смысл: выбрать корректные значения при расхождениях.

Важно провести сравнительный анализ моделей и выбрать ту, которая обеспечивает наилучшее качество предсказаний

Модель	Feature set	RMSE ↓	MAE ↓	R^2 ↑
CatBoost	full	0.6868	0.0687	0.9892
HistGradientBoosting	full	0.7198	0.0347	0.9895
Random Forest	full	1.6400	0.3191	0.9722
CatBoost	baseline	2.6061	0.3700	0.9351
Random Forest	baseline	2.6460	0.3836	0.9332

CatBoost выбран в качестве итоговой модели по следующим причинам:

1. Лучшее качество по ключевой метрике (RMSE). Минимизирует крупные ошибки предсказания высоты.

2. Устойчивость к пропускам и шуму
- корректно обрабатывает отсутствующие значения
- лучше работает на реальных данных с дефектами

3. Нативная работа с категориальными признаками
- не требует OneHotEncoding
- не раздувает пространство признаков
- автоматически учитывает взаимодействия

4. Хорошая обобщающая способность
- не переобучается на локальные геометрические паттерны
- стабильно работает в spatial CV

Валидация результатов позволяет подтвердить устойчивость алгоритма слияния и обоснованность выбора модели

Заполнение высот

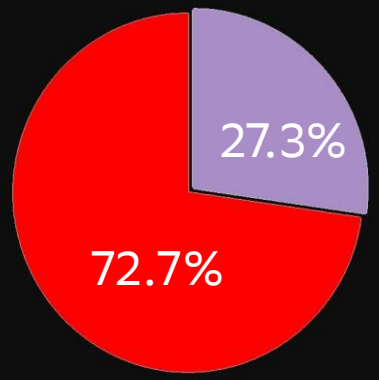

Предсказанные высоты (CatBoost)

Наблюдаемые высоты (из источников)

Физическая достоверность

Высота зданий	Минимум	Максимум
Площадь зданий	2.5 м	462.0 м
Площадь зданий	4.0 м²	141 492 м²
Этажность	1	38

Выбросы: 1 здание (Лахта-центр, 462 м)

Геометрическая корректность

100% Успешно преобразовано геометрий
0 Невалидных полигонов
0 Пустых геометрий
0 Нулевая / отрицательная площадь

Вывод

- ✓ Все геометрии валидны
- ✓ Все здания имеют высоту
- ✓ Диапазоны соответствуют реальной застройке
- ✓ Пространственная логика соблюдена (95% зданий согласованы с соседями)
- ✓ ML-заполнение выполнено корректно (только там, где не было данных)

Моделирование высот зданий позволяет обеспечить более стабильное качество связи и высокий уровень удовлетворенности клиентов МТС

- Тепловая карта высот (полная)

Распределение высот по городу. Синий — низкие, красный — высокие. Выделяются высотные доминанты, включая Лахта-центр (462 м).

- Тепловая карта высот (детальная, до 200 м)

Основная застройка (99.9% зданий) без сжатия цветовой шкалы под влиянием выбросов.

Executive Summary

- Карта доверия к высоте

Надёжность данных: синий — high, голубой — medium, оранжевый — low, жёлтый — предсказано.

- Тепловая карта доверия

Плотность зданий с высоким уровнем доверия. Оценка качества данных по районам.

- 3D-визуализация центрального района

Колонки от земли до высоты здания. Вертикальная структура застройки центра.

Полное решение кейса, включая код, блокноты и визуализации, размещено в репозитории по ссылке: https://github.com/hep2014/MTC-ItCup-2026

Приложение 1

Pipeline решения

Data → Matching → ML → Maps

От разведки и очистки данных до сопоставления, обучения модели и картографической визуализации

EDA
Первичная разведка данных
- структура источников A и B
- пропуски, типы, аномалии
- геометрические проверки

→

Очистка
Нормализация данных
- исправление геометрий
- удаление дублей и шумов
- подготовка к сопоставлению

→

Сопоставление и слияние
Граф совпадений между A и B
- IoU, overlaps, distance
- компоненты связности
- единый датасет

→

Анализ признаков
Формирование базы для модели
- статистика окружения
- агрегации по компонентам
- отбор информативных признаков

→

Обучение модели
Обучение финального решения
- сравнение baseline и ensemble
- обучение на признаках датасета
- заполнение высот / таргета

→

Валидация
Проверка качества результата
- MAE / RMSE / R^2
- сравнение по фолдам
- интерпретация ошибок

→

Карты и визуализация
Финальная интерпретация результата
- карты покрытия
- графовые и spatial-отчеты
- итоговые выводы

основные этапы пайплайна

критические точки сопоставления и проверки

дополнительные артефакты: визуалы, признаки, метрики

Приложение 2

Executive Summary

EDA • QUALITY DASHBOARD

Дэшборд первичного анализа

Краткий обзор качества двух источников перед дальнейшей очисткой и объединением данных.

Всего объектов
332 530
Общий объем двух источников

Строки с пропусками
10
Количество объектов, где есть хотя бы один пропуск

Некорректные геометрии
0
Объекты, требующие геометрической очистки

Подозрительные дубликаты
86
Кандидаты в дубликаты по геометрической сигнатуре

ОБЩАЯ КАРТИНА
332 530
На одной странице собраны только ключевые показатели, которые помогают быстро понять качество источников перед их объединением.

Источник A

171 454 объектов

Размер набора
171 454 × 8
Строки и колонки исходного источника

Строки с пропусками
5
Доля от всех объектов · 0,0%

Оценка качества
100
Низкий риск

Некорректные геометрии
0
Доля от объектов · 0,0%

Отсутствующие геометрии
0 / 0
Null · 0,0% / Empty · 0,0%

Успешный разбор геометрии
100,0%
Доля корректно прочитанных объектов в проверочной выборке

Подозрительные дубликаты
52
Кандидаты по сигнатуре · 0,0%

Ошибки контуров
8
Объекты с проблемами во внутренних границах

Числовые аномалии / площадь
420 / 171 454
Аномальные значения / объекты с заметным расхождением площади

Источник B

161 076 объектов

Размер набора
161 076 × 17
Строки и колонки исходного источника

Строки с пропусками
5
Доля от всех объектов · 0,0%

Оценка качества
100
Низкий риск

Некорректные геометрии
0
Доля от объектов · 0,0%

Отсутствующие геометрии
0 / 0
Null · 0,0% / Empty · 0,0%

Успешный разбор геометрии
100,0%
Доля корректно прочитанных объектов в проверочной выборке

Подозрительные дубликаты
34
Кандидаты по сигнатуре · 0,0%

Ошибки контуров
9
Объекты с проблемами во внутренних границах

Числовые аномалии
4 281
Аномальные значения основных числовых признаков

Сравнение

A vs B

	A	B
Объем данных	171 454	161 076
Строки с пропусками	5	5
Некорректные геометрии	0	0
Подозрительные дубликаты	52	34

- Главный приоритет — геометрическая корректность, потому что именно она определяет надежность пространственного сопоставления объектов.
- Пропуски оценены по числу строк, затронутых неполнотой, а не по сумме всех пустых ячеек.
- Подозрительные дубликаты и ошибки в контурах полезно разбирать до объединения источников, чтобы не переносить шум в итоговый датасет.

Приложение 3

Executive Summary

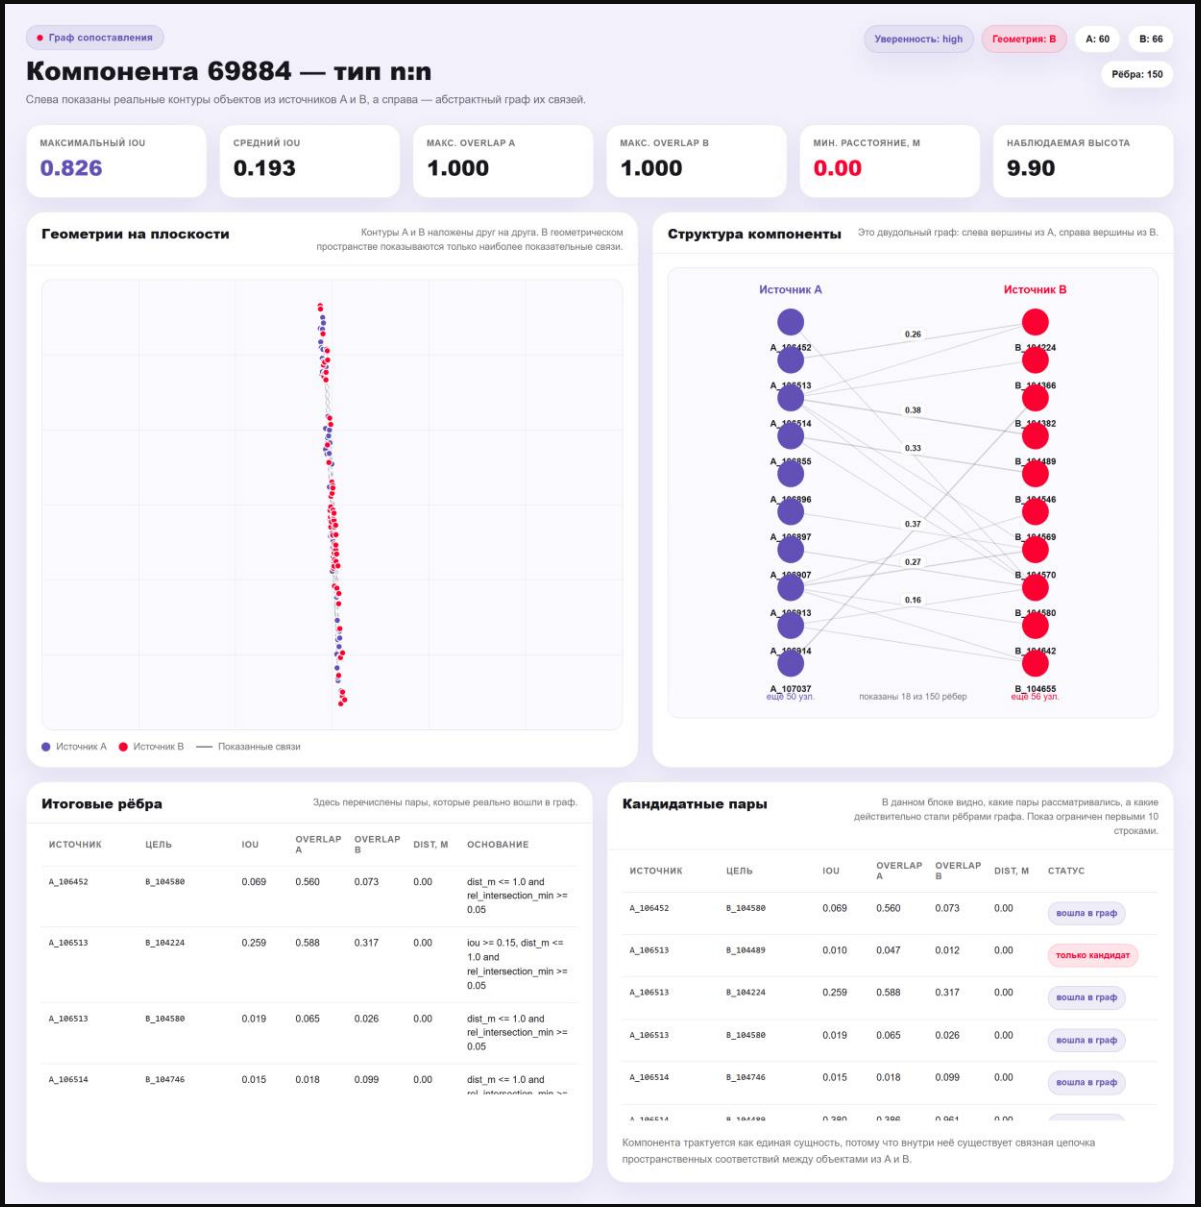

Приложение 4

Executive Summary

СРАВНЕНИЕ МОДЕЛЕЙ

CatBoost — основной победитель по качеству итогового решения

Среди полноценных моделей на полном наборе признаков именно CatBoost дал наилучший баланс ошибок и объясняющей способности, поэтому он был выбран как финальная модель для заполнения высоты зданий.

ФИНАЛЬНЫЙ ВЫБОР

CatBoost

- **Лучший RMSE** среди моделей на full feature set
- **Высокий R^2** — почти полный захват вариации целевой переменной
- **Сильнее baseline** более чем в 3 раза по RMSE

Сопоставление протестированных конфигураций

Шкалы приведены к единому виду: чем полоса длиннее, тем лучше

CatBoost — Лучший выбор
Полный набор признаков
Финальная модель

RMSE	0.6868
MAE	0.0687
R^2	0.9892

Лучший выбор для решения.

HistGradientBoosting
Полный набор признаков
Сильный конкурент

RMSE
MAE
R^2

Очень близкий результат.

Random Forest
Полный набор признаков
Рабочая альтернатива

RMSE	1.6400
MAE	0.3191
R^2	0.9722

CatBoost
Базовый набор признаков
Baseline

RMSE	2.6061
MAE	0.3700
R^2	0.9351

Random Forest
Базовый набор признаков
Baseline

RMSE	2.6460
MAE	0.3836
R^2	0.9332

Приложение 5

Executive Summary

POST-ML • VALIDATION DASHBOARD

Валидация результатов

Пост-ML валидация итогового датасета: геометрическая корректность, полнота высот, согласованность источников и пространственная правдоподобность результатов.

Всего зданий
139 649
Финальный датасет после сопоставления и заполнения высот

Высота заполнена
100,0%
139 649 из 139 649 объектов

Геометрия валидна
100,0%
Пустые, нулевые и невалидные полигоны не обнаружены либо сведены к минимуму

Предсказано моделью
27,3%
38 086 зданий получили высоту через CatBoost

ОБЩАЯ КАРТИНА
139 649
Итоговый набор после сопоставления, обучения и заполнения высот. Проверяем, что данные не только полны, но и логически согласованы.

Геометрия и полнота

53 колонок • 118,20 MB

Интегральная оценка валидации
100
Данные согласованы

Геометрическая корректность

Успешно разобрано
139 649 / 139 649
Доля успешного разбора · 100,0%

Невалидные геометрии
0
Доля от набора · 0,0%

Пустые / нулевая площадь
0 / 0
Пустые полигоны и вырожденные контуры

Отрицательная площадь
0
Физически невозможные значения площади

Полнота ключевых полей

target_height_filled
0
Пропусков · 0,0%

target_height_was_predicted
0
Пропусков · 0,0%

union_area_all
0
Пропусков · 0,0%

median_stairs_b
38 086
Ожидаемо для A_only · 27,3%

median_avg_floor_height_b
38 086
Связано с отсутствием данных источника B · 27,3%

Диапазоны и ML-логика

Observed vs CatBoost

Физическая достоверность значений

Высота
2,5 — 462,0 м
Отрицательных значений · 0

Этажность
1,0 — 38,0
Отрицательных значений · 0

Площадь
4,0 — 141 492,3 м²
Отрицательных значений · 0

Высотные выбросы
>300 м: 1
>500 м: 0

Целостность заполнения высот

Observed
101 563
Доля от набора · 72,7%

CatBoost
38 086
Доля от набора · 27,3%

Изменено observed
0
Должно быть 0: исходные наблюдения нельзя перезаписывать

Predicted с original height
0
Должно быть 0: модель заполняет только отсутствующие значения

Observed / predicted

Краткая статистика

Observed mean / median	9,5	4,5
Predicted mean / median	3,4	3,4
Observed min / max	2,5	462,0
Predicted min / max	3,1	3,9
Predicted std	0,03	узкий разброс